

Relatório de Análise Exploratória e Modelagem (Amostra de 10 Cidades - Paraná)

Disciplina: Pesquisa Operacional

Projeto: Otimização de Rotas de Vendas (Branch and Bound para o TSP)

Base de Dados: Amostra de 10 cidades do estado do Paraná, extraída do dataset "Brazilian Cities" (Kaggle).

1. Inspeção Inicial e Estrutura do Dataset

O objetivo deste projeto é encontrar a rota de menor custo para visitar um conjunto de 10 cidades no estado do Paraná.

Iniciamos com o dataset completo *brazilian_cities.csv*, que contém dados geográficos de milhares de cidades brasileiras. Para focar no problema de roteamento, realizamos um pré-processamento (via *pipeline_dados.py*) para selecionar apenas as variáveis essenciais:

- **CITY**: Nome da cidade.
- **STATE**: Estado (UF).
- **LAT**: Latitude geográfica.
- **LONG**: Longitude geográfica.

O **dataset final** utilizado para a modelagem e para esta análise exploratória consiste em:

1. **pontos_de_visita.csv**: Uma tabela contendo as 10 cidades selecionadas, com suas coordenadas.
2. **matriz_distancias.csv**: Uma matriz quadrada 10x10, onde cada célula (i, j) representa o custo (distância real de rodovia, em km) para viajar da cidade i para a cidade j .

2. Estatísticas Descritivas

A análise estatística focou na variável crítica para a otimização: o **custo da viagem** (distância em km) entre cada par de cidades distintas. A diagonal principal da matriz (distância de uma cidade para ela mesma, que é 0) foi excluída desta análise para não enviesar os resultados.


Resumo Estatístico das Distâncias (em km):

Métrica	Valor (km)	Interpretação
Média	337.87	A distância média entre duas cidades quaisquer da nossa amostra é de aproximadamente 338 km.
Mediana (Q2)	313.04	Metade das viagens possíveis entre as cidades têm menos de 313 km. A proximidade entre a média e a mediana sugere uma distribuição relativamente equilibrada, mas com uma leve tendência a viagens mais longas.
Desvio Padrão	158.45	Existe uma variação considerável nas distâncias. Isso é esperado, dado que selecionamos cidades aleatórias em um estado grande como o Paraná.
Mínimo	83.42	A viagem mais curta possível entre duas cidades da amostra. (Provavelmente entre cidades vizinhas na região noroeste).
Máximo	653.05	A viagem mais longa possível. (Provavelmente envolvendo a cidade de Curitiba, que está geograficamente isolada das demais na amostra).
Quartil 1 (25%)	213.87	25% das viagens são curtas, com menos de 214 km.
Quartil 3 (75%)	458.53	75% das viagens têm menos de 459 km. Isso significa que 25% das rotas possíveis são bastante longas (entre 459 km e 653 km).

3. Visualização Exploratória

3.1. Dispersão Geográfica das Cidades


O mapa abaixo mostra a localização exata das 10 cidades selecionadas.



Podemos observar uma concentração de cidades na região noroeste/oeste do estado, enquanto Curitiba aparece isolada no sudeste. Essa configuração geográfica sugere que qualquer rota ótima provavelmente visitará as cidades do noroeste em sequência antes ou depois de fazer o longo deslocamento até Curitiba.

3.2. Distribuição das Distâncias (Histograma e Boxplot)

Para entender melhor a variação dos custos, analisamos a distribuição das distâncias.




Análise:

- **Histograma:** Confirma que não temos uma distribuição normal perfeita. Há uma concentração de rotas na faixa de 200-400 km, mas também um número significativo de rotas longas (> 500 km).
- **Boxplot:** Mostra que a distribuição é relativamente simétrica em torno da mediana (313 km), sem *outliers* extremos (pontos muito fora da curva). Isso indica que, embora haja rotas longas, elas não são anomalias, mas sim características naturais da geografia do estado.

3.3. Matriz de Custos (Heatmap)

O heatmap nos permite visualizar todos os custos de uma só vez.



Análise:

- As áreas mais escuras (roxo/azul) representam as menores distâncias, indicando *clusters* de cidades próximas que o algoritmo deve tentar visitar em sequência.
- As áreas mais claras (amarelo/verde) representam as maiores distâncias. É possível notar que as linhas e colunas correspondentes a **Curitiba** tendem a ser mais claras, confirmando que ela é um ponto de alto custo para se conectar a qualquer outra cidade da amostra.

4. Conclusão e Adequação da Modelagem

A Análise Exploratória de Dados confirmou que a base selecionada é perfeitamente adequada e desafiadora o suficiente para o problema proposto.

Primeiramente, temos um **Grafo Completo**, já que a matriz de distâncias não possui valores nulos além da diagonal principal, indicando que é possível viajar diretamente entre quaisquer duas cidades, configurando um Problema do Caixeiro Viajante (TSP) clássico. Além disso, a **Variação de Custos** observada, com alta dispersão (desvio padrão de 158 km) e a existência de rotas muito longas (máx. 653 km), justifica o uso de um algoritmo de otimização exato como o Branch and Bound, pois uma heurística simples poderia facilmente levar a uma rota subótima ao escolher prematuramente uma cidade distante. Por fim, identificamos um claro **Candidato a Poda**: a cidade de Curitiba, por estar geograficamente isolada e gerar custos altos, é um excelente ponto para testes de análise de sensibilidade, pois sua presença ou ausência deve ter um impacto dramático na rota ótima e no custo total.